

《QA-GNN: Reasoning with Language Models and Knowledge Graphs for Question Answering》阅读报告

谭浩淞 许逸凡

摘要

预训练语言模型（LMs）与知识图谱（KGs）是问答系统的两类核心知识来源，但现有方法往往将二者视为分离的模态分别处理，导致语言理解无法与结构化知识推理深度协同。本文深入解读了斯坦福大学Yasunaga等人提出的QA-GNN模型，该模型通过“相关性评分”与“联合工作图”两大创新，实现了LM与KG在表示层面的深度融合。在CommonsenseQA、OpenBookQA和MedQA-USMLE三个基准上的实验表明，QA-GNN显著优于现有最优方法，尤其在处理否定等结构化推理问题上展现出独特优势。本报告从研究背景、现有方法局限、QA-GNN方法论、实验分析与可解释性、局限与拓展、代码复现与误差分析等维度，对该论文进行系统性技术解读。

仓库链接：github.com/tohsaka-sb/qagnn

一、背景介绍：问答系统中的知识困境

1.1 任务定义

QA是自然语言处理领域的核心任务之一。本文所针对的问答任务属于知识增强型多选问答，即给定一个问题和若干候选答案，系统需要利用外部知识进行推理，从而选出最合理的答案。

论文中主要考察了三个具有代表性的问答数据集：CommonsenseQA（常识推理问答）、OpenBookQA（开放书籍科学问答）和MedQA-USMLE（生物医学执业考试问答）。这些数据集的共同特点是：回答问题不仅需要理解问题本身的语义，还需要借助超出文本范围的背景知识进行推理判断。例如，CommonsenseQA中的问题“If it is not used for hair, a round brush is an example of what?”，正确答案为“art supplies”，这需要模型具备关于“圆刷”多种用途的常识知识，并能够理解否定词“not”带来的语义转折。

1.2 知识来源：预训练语言模型与知识图谱

当前问答系统主要依赖两类知识来源，二者各有优劣，形成了鲜明的互补关系：

预训练语言模型 (LMs)：以BERT、RoBERTa、T5等为代表的预训练语言模型通过在大规模无标注文本上进行自监督学习，隐式地编码了丰富的世界知识。然而，其局限性也十分明显：

- **结构化推理能力不足**：LMs在处理需要精确逻辑组合、比较或否定操作的复杂问题时常常失败。Kassner和Schütze (2020) 的研究表明，预训练语言模型在处理否定等结构化语言现象时表现不佳，倾向于依赖表面统计模式，而非真正的逻辑推理。
- **缺乏可解释性与透明度**：LMs如同一个“黑箱”，很难追溯其得出某个答案的具体推理过程。
- **知识更新困难**：LMs的知识冻结在训练时刻，若要更新通常需要昂贵的重新训练。

知识图谱 (KGs)：知识图谱以结构化的三元组形式显式表示世界知识，例如ConceptNet、Freebase等。其优势在于结构化与精确性、强可解释性，天然适合进行多跳路径推导。但其局限性也十分突出：KGs通常面临知识覆盖度不足和噪声问题，人工构建的KGs难以容纳现实世界所有知识，不相关的实体和边会引入噪声，干扰推理。

1.3 研究动机

正是基于上述两种知识源各自的优势和不足，**如何将LMs的广泛覆盖和语义理解能力，与KGs的结构化推理和可解释性相结合，成为一个重要的开放性问题**。QA-GNN论文正是在此背景下，致力于解决LM和KG融合中的两个关键挑战：（1）如何从庞大的KG中精准识别与问题相关的知识；（2）如何进行有效的联合推理，而非将两者作为独立的模态分别处理。

二、现有方法及其局限性与QA-GNN的设计动机

2.1 现有方法范式

1. **KG子图检索**：给定问题 q 和候选答案 a ，识别出问题与选项中提及的主题实体 $\mathcal{V}_{q,a}$ ，然后从外部KG中检索包含这些实体及其 k 跳内邻居的子图 G_{sub} 。
2. **分离编码**：使用预训练LM对问答上下文编码得到向量 z^{LM} ；同时使用GNN对检索到的子图编码得到向量 g 。
3. **特征融合与预测**：将 z^{LM} 和 g 拼接，通过MLP融合并给出最终答案分数。

在此框架下的代表性工作包括：RGCN（关系图卷积网络）、GconAttn（图注意力机制）、KagNet（路径特征建模）、MHGRN（多跳图关系网络，该框架下性能最强）。

2.2 现有方法的局限性

尽管上述方法取得了一定进展，但本文精确地指出了它们的两个核心缺陷：

(1) 相关性盲目的子图噪声问题：现有方法在检索KG子图时，对 k 跳邻居的选取是无差别的。当主题实体数量多或跳数 k 增大时，子图规模急剧膨胀，包含大量与问题语义无关的“离题”节点或过于通用的节点。这些无关节点不仅增加计算负担，还可能导致错误推理。现有方法缺乏根据问题上下文动态评估并过滤KG节点相关性的机制。

(2) 模态分离的浅层推理问题：现有方法将LM和KG视为两个独立的处理管道。LM编码的 z^{LM} 无法感知KG子图的具体结构；GNN处理KG时也无法利用LM的深层语义指导消息传递。尽管最后通过拼接向量融合，但这种浅层、后期的交互方式，无法实现两种知识源在概念层面的相互校准和深层推理。例如，当问题中包含否定词时，GNN端难以抑制与被否定概念相关的路径。

论文通过实验验证了上述局限：在CommonsenseQA上，MHGRN相比纯RoBERTa仅提升2.4%，而在包含否定词的问题上仅提升0.6%，说明现有方法在结构化推理方面的改进十分有限。

2.3 QA-GNN的设计动机与核心创新

为克服上述局限，QA-GNN提出了两个关键创新：

创新一：基于语言模型条件的KG节点相关性评分

- **机制：**QA-GNN利用预训练LM本身的知识评估能力，计算每个KG节点 v 相对于当前问答上下文 z 的“相关性得分” ρ_v 。具体地，将节点 v 的文本和问答上下文 z 的文本拼接，输入LM，通过MLP头计算标量分数。
- **优越性：**这个机制提供了一种动态的、语义感知的剪枝和加权策略，能够前瞻性地识别并抑制噪声节点，强化重要节点的作用。实验证明，这种方法显著提升了在包含大量实体的问题上的性能。

创新二：基于工作图的联合推理

- **机制：**QA-GNN将问答上下文本身视为一个特殊节点 z ，并使用两种新边将其与子图中的主题实体连接起来，形成包含语言和知识两种模态信息的单一异构工作图*。
- **优越性：**这个工作图构成了一个“联合推理空间”。在此之上，GNN进行多轮消息传递时，语言模态的节点 z 也深度参与： z 的表示在每一层被更新，能从相连的KG节点聚合信息，同时影响周围KG节点的表示更新。例如， z 中编码的“否定”语义可通过注意力机制传递到被否定的实体节点，削弱其影响。这种深度、早期的交互使语言理解和结构化知识推理融为一体、相互促进。

三、论文提出的方法：QA-GNN模型详解

3.1 问题形式化

论文首先对任务进行了严格的形式化定义：

- **语言模型**：将LM定义为编码器 f_{enc} 和任务头 f_{head} 的复合函数，即 $f_{head}(f_{enc}(x))$ 。
- **知识图谱**：定义为一个多关系图 $G = (V, E)$ ，其中 V 是实体节点集合， $E \subseteq V \times R \times V$ 是边集合， R 是关系类型集合。
- **问答上下文**：给定问题 q 和答案选项 $a \in C$ ，问题中提到的KG实体记为 V_q （问题实体），答案选项中提到的实体记为 V_a （答案实体），两者合称**主题实体** $V_{q,a} = V_q \cup V_a$ 。
- **子图检索**：从KG中提取包含主题实体之间所有k跳路径的子图 $G_{sub} = (V_{sub}, E_{sub})$ 。

3.2 联合图表示：联合推理空间的诞生

为了构建QA上下文与KG的联合推理空间，本文引入了QA上下文节点 z ：

- 将问题和答案选项拼接为QA上下文 $[q; a]$ ，用一个特殊节点 z 表示整个QA上下文。其输入文本格式遵循BERT/RoBERTa的标准输入范式： $text(z) = [CLS] + Question + [SEP] + Answer_Choice + [SEP]$ 。其中 $[CLS]$ 分类标记用于聚合整个输入序列的语义信息， $[SEP]$ 分隔符用于分隔问题文本和答案选项文本，让模型明确区分两部分内容。整个序列经过LM编码后， $[CLS]$ 标记的输出向量即作为该QA上下文节点 z 的初始嵌入 z_{LM} 。
- 将 z 与KG子图中的所有主题实体 $V_{q,a}$ 连接，使用两种新的关系类型 $r_{z,q}$ 和 $r_{z,a}$ 分别表示 z 与问题实体和答案实体之间的关系。

由此构建的**工作图** $G_W = (V_W, E_W)$ 统一了语言知识和结构化知识两个模态，其中 $V_W = V_{sub} \cup \{z\}$ ， $E_W = E_{sub} \cup \{(z, r_{z,q}, v) | v \in V_q\} \cup \{(z, r_{z,a}, v) | v \in V_a\}$ 。

工作图中的每个节点属于四种类型之一： $T = \{Z, Q, A, O\}$ ，分别表示QA上下文节点、问题实体节点、答案实体节点和其他节点。

节点初始化：

- QA上下文节点 z 的初始嵌入： $z_{LM} = f_{enc}(text(z))$ 。
- KG实体节点 $v \in V_{sub}$ 使用预训练的实体嵌入初始化。

3.3 KG节点相关性评分：语义感知的噪声过滤

由于检索得到的KG子图 G_{sub} 包含大量无关节点，本文提出使用预训练LM对KG节点进行相关性评分：

$$\rho_v = f_{head}(f_{enc}([text(z); text(v)]))$$

该分数反映了KG节点在当前QA上下文下的重要性，具有以下特点：

- **语言条件化**：评分直接依赖于QA上下文的语义，而非PageRank等与当前问题无关的图统计指标。
- **双重用途**：既用于剪枝KG子图（保留Top 200节点），又作为节点特征增强GNN的推理能力。

3.4 GNN架构：节点类型、关系与分数感知的注意力网络

在工作图 G_W 上，本文设计了基于GAT的GNN模块进行多轮消息传递推理。

基本消息传递框架：

$$h_t^{(l+1)} = f_n \left(\sum_{s \in N_t \cup \{t\}} \alpha_{st} m_{st} + h_t^{(l)} \right)$$

其中 f_n 是带批归一化的两层MLP，使用残差连接。

节点类型与关系感知的消息：

- 类型嵌入： $u_t = f_u(u_t)$, $u_t \in \{0, 1\}^{|T|}$ 为节点类型的one-hot向量。
- 关系嵌入： $r_{st} = f_r(e_{st}, u_s, u_t)$, $e_{st} \in \{0, 1\}^{|R|}$ 为关系类型的one-hot向量。
- 消息计算： $m_{st} = f_m(h_s^{(l)}, u_s, r_{st})$

节点类型、关系与分数感知的注意力：

- 相关性分数嵌入： $\tilde{\rho}_t = f_\rho(\rho_t)$
- 查询向量： $q_s = f_q(h_s^{(l)}, u_s, \tilde{\rho}_s)$
- 键向量： $k_t = f_k(h_t^{(l)}, u_t, \tilde{\rho}_t, r_{st})$
- 注意力权重： $\alpha_{st} = \frac{\exp(\gamma_{st})}{\sum_{t'} \exp(\gamma_{st'})}$, $\gamma_{st} = \frac{q_s^\top k_t}{\sqrt{D}}$

这种设计使得注意力机制能够动态评估图中各种信息的流转强度，一个节点的相关性高低会影响它"想从邻居获取多少信息"的查询强度。

3.5 推理与学习

对于给定的问题 q 和答案选项 a ，模型综合三方面信息进行预测：

$$p(a|q) \propto \exp(\text{MLP}(z_{\text{LM}}, z_{\text{GNN}}, g))$$

其中 $z_{\text{GNN}} = h_z^{(L)}$ 是GNN最终层QA上下文节点的表示， g 是KG节点表示的池化。训练采用交叉熵损失进行端到端优化，LM和GNN的参数联合更新。

3.6 计算复杂度分析

论文对QA-GNN的计算复杂度进行了理论分析。QA-GNN的时间复杂度为 $O(|V|\Delta L)$ (稀疏图)，其中 Δ 是最大节点度， L 是GNN层数。由于使用统一的边嵌入处理不同关系类型，时间复杂度与关系数量无关，空间复杂度与MHGRN相同，在处理大规模多关系图时更加高效。

四、实验结果与分析

4.1 实验设置

数据集： CommonsenseQA、OpenBookQA、MedQA-USMLE。

知识图谱： CommonsenseQA和OpenBookQA使用ConceptNet (799,273节点, 2,487,810边)；MedQA-USMLE使用整合UMLS和DrugBank的生物医学KG (9,958节点, 44,561边)。

基线模型： 微调LM (RoBERTa-large、AristoRoBERTa、SapBERT) 和现有LM+KG模型 (RGCN、GconAttn、KagNet、RN、MHGRN)。

实现细节： GNN维度 $D = 200$ ，层数 $L = 5$ ，dropout率0.2，RAdam优化器，双GPU训练约20小时。

4.2 主实验结果

CommonsenseQA (Table 3)：QA-GNN在IHdev达到**76.54%**，IHtest达到**73.41%**。相比RoBERTa提升 $+4.7\%$ ，相比MHGRN提升 $+2.3\%$ 。官方测试集排行榜达到76.1%，同等规模模型中最优。

OpenBookQA (Table 5)：AristoRoBERTa + QA-GNN达到**82.77%**，优于MHGRN (80.6%) 和纯AristoRoBERTa (78.40%)。

MedQA-USMLE (Table 7)：SapBERT + QA-GNN达到**38.0%**，优于SapBERT (37.2%) 和BioBERT-large (36.7%)，表明QA-GNN在不同领域均能有效增强LM。

4.3 消融实验

论文在CommonsenseQA IHdev上对各组件进行了详细的消融研究 (Table 8)：

图连接方式 (Graph Connection)：

- 无QA上下文节点与KG的连接：74.81% (接近MHGRN的74.45%)
- z 连接到所有KG节点：76.31%
- z 仅连接到主题实体 $V_{q,a}$ (最终方案)：**76.54%**

结果表明，将QA上下文节点与KG连接是实现联合推理的关键，但连接到所有KG节点会引入噪声，仅连接主题实体效果最佳。

相关性评分 (Relevance Scoring) :

- 无相关性评分：75.56%
- 使用上下文嵌入：76.31%
- 使用相关性分数：76.54%
- 同时使用两者：76.52% (与仅使用分数相当)

GNN架构设计:

- 仅类型感知 (type-aware) : 75.41%
- 仅关系感知 (relation-aware) : 75.61%
- 仅分数感知 (score-aware) : 75.56%
- 三者结合：76.54%

GNN层数:

- $L = 3$: 75.53%; $L = 4$: 76.34%;
- $L = 5$: 76.54%; $L = 6$: 76.21%;
- $L = 7$: 75.96%

4.4 模型可解释性分析：从路径到子图

论文通过可视化GNN的节点间注意力权重来解释模型的推理过程。与之前只能提取单条路径的方法不同，QA-GNN可以发现更一般的子图结构（如多锚节点子图），提供了更丰富的可解释性。

示例 (a) : 问题"Where would you find a basement that can be accessed with an elevator?". 从QA上下文节点 z 出发，注意力流向问题实体"elevator"和"basement"，再流向"building"，最终指向答案"office building"。这构成了一个清晰的多跳推理子图，展示了模型如何从语言上下文出发，在KG上进行结构化推导。

示例 (b) : 问题"Crabs live in what sort of environment?"（螃蟹生活在什么环境中？）。注意力从两个方向 ($Z \rightarrow Q \rightarrow O$ 和 $Z \rightarrow A \rightarrow O$) 汇聚到"sea"和"ocean"，这些概念未在问题中直接提及，但在KG中桥接了问题实体"crab"和答案"salt water"。这体现了工作图中多锚点汇聚推理的优势——模型能够同时从问题和答案两个方向在KG上探索，找到共同的中间概念作为推理桥梁。

这种子图级别的可解释性比传统路径方法更丰富：路径方法只能给出几条线性的推理链，而QA-GNN的注意力分布揭示了一个完整的推理子图，其中可能包含多个并行的推理路径和汇聚点，更贴近人类进行常识推理时的"联想网络"模式。

4.5 结构化推理能力分析

否定词处理 (Table 10) : 论文专门分析了模型在包含否定词 (no, not, nothing, unlikely等) 的问题上的表现:

- RoBERTa-large: 54.2%
- KagNet: 54.2% (+0.0%)
- MHGRN: 54.8% (+0.6%)
- QA-GNN: 58.8% (+4.6%)

当移除 z 与KG节点之间的连接后, QA-GNN在否定问题上的性能降至55.1%, 接近MHGRN水平, 说明**联合消息传递**是处理结构化推理的关键。深度联合推理使得语言中的否定语义能够有效地传导到知识图谱推理中, 抑制了错误路径。

4.6 相关性评分的效果分析

论文进一步分析了KG节点相关性评分在不同场景下的作用 (Table 11) :

- 对于包含较少实体 (≤ 10 个) 的问题 (平均90个KG节点) : MHGRN 71.5%, QA-GNN (无相关性评分) 72.8%, QA-GNN (有相关性评分) 73.4%
- 对于包含较多实体 (> 10 个) 的问题 (平均160个KG节点) : MHGRN 70.1%, QA-GNN (无相关性评分) 71.5%, QA-GNN (有相关性评分) 73.5%

结果表明, 当检索的KG较大时 (实体多的问题), 相关性评分的收益更为明显 (从71.5%提升到73.5%), 有效缓解了噪声节点带来的问题。这直接证明了**相关性评分机制在应对大规模、高噪声子图时的关键作用**, 提升了模型的鲁棒性和可扩展性。

五、方法的局限性及可能的拓展方向

尽管QA-GNN取得了显著成功, 但技术的进步总是在不断审视局限性中前进。

5.1 存在的局限性

(1) 对实体链接质量与KG覆盖的依赖性: QA-GNN的性能上限仍受限于外部KG的覆盖度和准确性。如果关键推理所需的关系或实体完全不存在于KG中 ("知识空档"), 模型将无能为力。同时, KG中存在的错误关联也可能通过GNN传播, 导致错误推理。此外, QA-GNN依赖于将问题和答案选项中的提及链接到KG实体的预处理步骤, 实体链接的错误会直接传播到后续的子图检索和推理过程。对于未在KG中覆盖的实体或存在歧义的实体提及, 模型难以正确处理。

(2) 从KG检索子图的瓶颈：尽管相关性评分能对检索到的子图进行有效过滤，但初始子图的生成（如2跳邻居）本身就是一个计算密集型且启发式的过程。如何在不遗漏重要远程依赖的情况下，高效、智能地检索出初始候选子图，仍是一个挑战。

(3) 结构化推理能力的边界：虽然QA-GNN在处理简单否定上表现出色，但论文也指出，它无法正确处理“双重否定”（如“不是不有趣”）。这表明模型并未真正掌握否定逻辑的代数法则，其“推理”可能更多是一种模式匹配，而非严格的逻辑演绎。对于更复杂的逻辑组合（如嵌套量词、条件句等），模型可能也会失效。

(4) 静态知识的局限：整个知识来源（LM参数和KG结构）在推理时是固定的。模型无法处理需要动态链接外部知识库（如实时数据库）或需要多步交互式推理（如通过搜索引擎或API获取新信息）的任务。

(5) 计算开销：每次推理都需要构建工作图并通过多层GNN，且相关性评分需要对每个KG节点进行LM前向计算，其在线推理的延迟和计算成本，相比于仅使用微调后LM的方法更高，可能限制了在极致低延迟、高吞吐场景下的部署。

(6) 答案选项的独立性假设：在多选问答设置中，QA-GNN独立地对每个问题-答案选项对进行评分，未显式建模选项之间的对比关系。某些问题可能需要比较不同选项的相对优劣，而非独立判断每个选项的合理性。

5.2 未来拓展方向

(1) 动态、多源知识融合：

- **检索增强生成（RAG）结合：**将QA-GNN的推理能力与RAG等框架结合，让模型在推理过程中不仅能从KG检索子图，还能从Wikipedia等文本语料库中动态检索相关段落作为补充节点或证据，实现更开放域的问答。
- **与基于文本的KG推理结合：**利用预训练LM生成或补全KG中缺失的边，以在线方式动态扩展工作图，缓解KG稀疏性问题。
- **多源KG融合：**QA-GNN目前使用单一KG作为结构化知识源。拓展方向包括同时融合多个异构KG（如将ConceptNet与Wikidata结合），或将结构化KG与非结构化文本知识统一建模，实现更全面的知识覆盖。

(2) 更深层次的语言-结构对齐与预训练：

- **生成式预训练：**设计一个联合的预训练目标，让模型在大规模语料和KGs上，像T5一样以生成任务的方式学会在LM和KG之间进行翻译、桥接和推理，而不是仅限于分类任务。例如，给定KG子图生成文本，或反之亦然。
- **跨模态对比学习：**将KG中的三元组和可能表达相同知识的自然语言句子进行对比学习，从而学到更鲁棒的、对齐的联合表示空间。

- **大规模预训练与统一框架**：受UnifiedQA、T5等统一文本到文本框架的启发，可以探索将QA-GNN的联合推理能力整合到大规模预训练模型中，在预训练阶段就引入KG知识，实现更通用的知识增强型语言模型。

(3) 向更复杂的推理迈进：

- **结合符号推理器**：将QA-GNN作为“直觉系统”，提取结构化的证据子图，然后将其输入到一个显式的符号推理器（如逻辑编程或模糊逻辑系统）中进行最终裁决，结合了神经网络的鲁棒性和符号系统的精确性。
- **推理链（Chain-of-Thought）联合建模**：让模型不仅输出答案，还可以在图谱上生成多跳推理路径和自然语言解释的混合推理链，进一步增强可解释性和复杂推理能力。
- **自适应深度推理网络**：当前GNN使用固定层数的消息传递。可以探索根据问题的复杂度动态调整推理步数的自适应网络，避免过浅导致的推理不充分和过深导致的过平滑问题。

(4) **效率与可扩展性优化**：研究更高效的GNN架构（如图采样、小批量训练、推理时的图剪枝技术），以降低计算成本，支持在更大规模的知识图谱（如整个Wikidata）上进行推理。

(5) **零样本与少样本迁移**：QA-GNN目前在有充足标注数据的数据集上进行微调。未来可以研究如何将在一个领域（如常识问答）上训练的QA-GNN迁移到新的领域或任务，减少对新领域标注数据的依赖。

六、代码分析复现：从论文方法到本地实验的验证

前文已经从模型结构、实验结果、可解释性与方法局限等角度分析了QA-GNN的技术价值。为了进一步检验论文方法在真实工程环境中的可复现性，本节转向代码层面的实践分析。与前五部分偏重论文内容解读不同，本节关注的是：在当前公开代码、现代依赖环境与本地硬件条件下，QA-GNN能否顺利完成从数据预处理、图构建到训练评测的完整闭环；如果最终指标与论文结果存在明显差距，差距可能来自哪些环节。

6.1 复现目标与评价标准

本次复现对象为论文对应的 `qagnn-main` 代码仓库，主要选择CommonsenseQA的in-house split作为验证任务。这一选择与论文主实验中的CommonsenseQA设置保持一致，也便于直接对照论文Table 3中的IHdev与IHtest指标。

复现目标可以分为两个层次：

1. **工程复现目标**：验证代码是否能够在本地环境中完成完整流程，包括statement生成、concept grounding、KG子图抽取、模型训练、checkpoint保存与验证集/测试集评测。

2. **数值复现目标**：验证在相近实验设置下，模型是否能够接近论文报告的性能，即IHdev约76.54%、IHtest约73.41%的准确率水平。

这样的划分是必要的，因为一个模型“代码能够跑通”并不等同于“论文指标能够复现”。对于QA-GNN这类同时依赖LM、KG、实体链接、图构建和GNN训练的系统，任一预处理或依赖版本差异都可能在最终准确率上被放大。因此，本节不只记录运行结果，也对复现误差的来源进行分析。

6.2 本地运行环境与数据链路

本次实验在Windows主机的WSL环境下完成，Python环境为Conda环境 `amem_env`，主要基模为 `roberta-large`，GPU为NVIDIA GeForce RTX 5060 Ti，显存为8GB。受显存限制，训练过程中需要依赖较小batch、断点续跑以及离线缓存等策略来保证流程稳定推进。

在数据层面，本次复现围绕CSQA in-house split展开，整体链路与QA-GNN原始设计基本一致：首先将原始问答样本转换为statement格式，然后进行concept grounding，将问题和答案中的实体提及链接到ConceptNet概念；随后基于这些概念抽取相关KG子图，生成图邻接文件；最后将文本输入、实体节点、图结构和预训练实体向量一并送入QA-GNN进行训练与评测。

关键数据文件包括：

- `data/csqa/statement/*.statement.jsonl`：由多选问答样本转换得到的自然语言statement；
- `data/csqa/grounded/*.grounded.jsonl`：实体链接后的grounding结果；
- `data/csqa/graph/*.graph.adj.pk`：图抽取阶段生成的子图邻接结构；
- `data/csqa/inhouse_split_qids.txt`：CSQA in-house划分文件，共8500行。

其中，`inhouse_split_qids.txt` 的全部QID均属于训练statement的QID子集，说明基本数据划分没有出现明显错位。ConceptNet词表 `data/cpnet/concept.txt` 的行数为799273，也与后续实体嵌入文件的规模相匹配。

6.3 为适配现代环境所做的工程修复

原始QA-GNN代码依赖的Python包、PyTorch版本、Transformers接口和NetworkX序列化方式与当前环境存在不兼容之处，因此复现过程中首先需要完成若干工程修复。这些修改并非为了改变模型结构，而是为了让原始流程在现代依赖栈下能够正常执行。

主要修改包括以下几类：

- 在 `modeling/modeling_encoder.py` 中，移除对旧版 `transformers` 常量表的依赖，改为根据模型名称推断编码器类型；
- 在 `utils/optimization_utils.py` 中，适配当前PyTorch环境下 `AdamW` 与 `RAdam` 的调用方式；

- 在 `utils/grounding.py` 中，适配spaCy 3的API变化，并加入grounding阶段的断点续跑能力；
- 在 `utils/graph.py` 中，兼容新版NetworkX对gpickle读写方式的变化，同时增加图生成阶段的分块缓存与续跑机制；
- 在 `qagnn.py` 中，增加训练断点续跑逻辑，保存 `checkpoint_last.pt`，并兼容PyTorch 2.6以后 `torch.load(weights_only=...)` 的行为变化；
- 在训练和评测脚本中，设置离线优先策略，如 `TRANSFORMERS_OFFLINE=1`，并让 `run_qagnn_csqa.sh` 支持自动续跑。

这些改动使得代码从“依赖冲突、难以启动”的状态转变为“可预处理、可训练、可中断后续跑”的状态。也就是说，当前复现失败的核心并不是程序无法运行，而是运行后的性能指标与论文报告值存在显著差距。

6.4 关键资源文件的一致性检查

由于QA-GNN高度依赖ConceptNet实体嵌入，`data/cpnet/tzw.ent.npy` 的完整性是影响结果的重要因素。复现过程中曾发现旧版 `tzw.ent.npy` 存在损坏现象，读取时报错 `mmap length is greater than file size`。虽然修复版 `tzw.ent.repaired.npy` 可以被读取，但抽样检查显示全零行比例约为0.6127，说明其语义信息已经严重退化，不能作为可靠的实体嵌入使用。

随后重新下载原始 `tzw.ent.npy` 并进行一致性校验，结果如下：

- `shape = (799273, 1024) ;`
- `dtype = float32 ;`
- `sample_zero_row_ratio = 0.000000 。`

这说明当前使用的实体嵌入文件在形状、数据类型和非零分布上均已恢复正常。结合 `concept.txt` 的799273行词表规模，可以确认ConceptNet词表与实体嵌入之间不存在明显维度不匹配问题。

不过，后续实验表明，替换回完整的原始 `tzw.ent.npy` 并没有将模型性能提升到论文水平。这一点非常关键：它说明损坏的实体嵌入确实是一个严重问题，但并不是解释30个百分点以上性能差距的唯一原因。

6.5 本地实验结果与论文结果对比

论文Table 3中，QA-GNN在CommonsenseQA in-house split上的报告结果为：

- IHdev: 76.54 ± 0.21 ;
- IHtest: 73.41 ± 0.92 。

本地复现中记录了两个关键实验。

Run A: 完整15 epoch历史主实验

- 结果目录: `saved_models/csqa/enc-roberta-large_k5_gnndim200_bs64_seed0_20260520_203520` ;
- 根据 `log.csv` 中dev最大值选择best checkpoint;
- best `dev_acc = 0.4464` , 即44.64%;
- 对应 `test_acc = 0.4263` , 即42.63%。

Run B: 改回原始 `twz.ent.npy` 后的实验

- 结果目录: `saved_models/csqa/enc-roberta-large_k5_gnndim200_bs64_seed0_embtwz_ufz4_20260522_182718` ;
- 当前记录到epoch 3, 后续因 `KeyboardInterrupt` 中断;
- best `dev_acc = 0.4316` , 即43.16%;
- 对应 `test_acc = 0.4085` , 即40.85%。

以Run A的best结果与论文Table 3对比, IHdev差距约为31.90个百分点, IHtest差距约为30.78个百分点。该差距已经远大于论文报告中的随机种子波动范围, 因此不能简单归因于单次训练不稳定或seed差异。换言之, 本地实验已经完成了工程意义上的闭环复现, 但尚未完成论文数值意义上的指标复现。

6.6 误差来源分析

结合前文对QA-GNN结构的分析, 可以看到该模型的性能不仅取决于RoBERTa编码器和GNN本身, 还强烈依赖KG侧预处理质量。因此, 本地结果与论文结果之间的差距更可能来自系统链路中的复合偏差, 而不是某一个孤立参数。

首先, **预处理产物与论文实验产物可能并非同源**。本次最终使用的图数据来自本地重建流程, 包括grounding和graph extraction, 而不是论文作者当时发布或内部使用的完全同版预处理包。对于QA-GNN而言, concept grounding的召回率、歧义处理、停用词过滤、ConceptNet版本、路径抽取规则等都会直接改变工作图 G_W 的节点和边。一旦主题实体或关键中间节点发生偏移, 后续GNN即使结构正确, 也很难恢复论文中的推理路径。

其次, **依赖栈迁移可能带来行为漂移**。为了让代码在当前环境下运行, 复现过程中对编码器加载、优化器、图文件读取和checkpoint加载逻辑进行了兼容性修改。这些修改从设计意图上并未改变QA-GNN的核心结构, 但现代Transformers、PyTorch和spaCy的默认行为与旧版本并不完全一致。例如tokenizer细节、优化器实现、随机数行为、权重加载严格性等因素, 都可能影响训练轨迹。

再次, **官方checkpoint与当前代码栈之间存在不兼容迹象**。尝试加载仓库提供的预训练模型时, 出现了 `state_dict` 键不匹配问题, 例如 `encoder.module.embeddings.position_ids` 相关差

异。这说明当前代码、权重文件和依赖版本之间并未完全对齐，也削弱了直接复验官方结果的可行性。

最后，**硬件约束影响了完整实验效率**。在8GB显存条件下，`unfreeze_epoch=4` 之后训练速度明显下降，中断与续跑成为必要策略。虽然这并不必然导致低准确率，但它提高了完整多seed、多epoch对照实验的成本，使得定位误差来源更加困难。

6.7 复现结论与对论文方法的再评价

综合上述结果，本次复现可以得到两个层面的结论。

第一，从工程角度看，QA-GNN的完整流程已经被跑通。经过依赖适配和断点续跑改造后，代码能够完成数据预处理、图构建、训练、保存和评测，说明公开代码仍具有较高的工程参考价值。

第二，从数值复现角度看，本地结果与论文Table 3之间仍存在约30个百分点的显著差距。当前证据表明，这一差距不能由单次随机波动解释，也不能完全归因于曾经损坏的 `twz.ent.npy` 文件。更合理的判断是：在当前公开可得资源、现代依赖栈和本地重建预处理流程下，QA-GNN尚未复现论文报告的数值结果。

在当前公开工件与本地环境约束下，本文完成了QA-GNN的工程复现，但未能复现论文在CommonsenseQA in-house split上的报告指标；性能差距可能主要来自预处理产物、依赖版本和权重兼容性等复合因素。

这一复现结果也反过来印证了前文第五部分关于QA-GNN局限性的讨论：该模型虽然在理论上实现了LM与KG的深度融合，但其效果高度依赖外部KG、实体链接和图构建质量。也就是说，QA-GNN的优势并不只来自模型结构本身，还来自一整套较精细的知识预处理管线。若这条管线发生偏移，联合推理空间的质量会显著下降，最终影响模型性能。

6.8 已产出材料与可审计证据

为保证复现过程可追溯，本次实验保留了以下材料：

- 训练脚本与配置：`run_qagnn_csqa.sh`；
- 一致性校验脚本：`scripts/verify_cpnet_assets.py`；
- 关键日志：
 - `logs/train_csqa_enc-roberta-large_k5_gnndim200_bs64_seed0_20260520_203520.log.txt`；
 - `logs/train_csqa_enc-roberta-large_k5_gnndim200_bs64_seed0_embtwz_ufz4_20260522_182718.log.txt`；
- 关键结果文件：

- `saved_models/csqa/enc-roberta-large__k5__gnndim200__bs64__seed0__20260520_203520/log.csv` ;
- `saved_models/csqa/enc-roberta-large__k5__gnndim200__bs64__seed0__embtzw__ufz4__20260522_182718/log.csv` 。

这些材料共同构成了本次复现的审计依据，也为后续继续定位差距来源提供了基础。若进一步推进数值复现，优先方向应是对齐论文原始预处理产物、锁定旧版依赖环境，并使用官方checkpoint进行严格的逐项兼容性检查。

七、总结

综合论文解读与本地复现结果来看，QA-GNN通过在统一的工作图上进行语言与知识图谱的深度融合与联合推理，确实为知识增强型问答提供了一种具有启发性的技术路径。其“相关性评分”和“联合工作图”的设计，不仅在论文实验中带来了性能提升，也在处理结构化语言现象和提升可解释性方面展现出较强潜力。与此同时，代码复现部分也表明，这类LM+KG系统的最终效果高度依赖预处理管线、外部知识资源和依赖环境的一致性。

具体而言，QA-GNN的两个核心创新各有其独特价值：**相关性评分机制**提供了一种动态的、语义感知的噪声过滤策略，使得模型能够在海量KG节点中精准聚焦与当前问题相关的知识；**联合工作图**则打破了LM与KG之间的模态壁垒，通过GNN消息传递实现了语言理解与结构化推理的深度融合，使二者能够相互校准、相互增强。

实验结果表明，QA-GNN在常识问答、科学问答和生物医学问答上均显著优于现有基线，尤其在处理否定等结构化推理问题上展现出独特优势。可解释性分析进一步揭示了模型如何通过注意力机制在KG上进行多跳子图推理，提供了比传统路径方法更丰富的推理证据。

尽管存在对图谱质量依赖、复杂逻辑处理边界、计算开销等局限，但QA-GNN为如何有效结合语言模型和知识图谱进行联合推理提供了重要的技术思路和实践经验。其“将语言上下文作为图节点”的设计思想具有范式意义，将语言表示直接纳入图神经网络的消息传递框架，开创了LM与KG深度融合的新路径。这一思想必将启迪未来更多关于多模态知识融合、可解释AI以及复杂推理的研究，推动知识增强型问答系统向更智能、更可靠的方向发展。

参考文献

Yasunaga, M., Ren, H., Bosselut, A., Liang, P., & Leskovec, J. (2022). QA-GNN: Reasoning with Language Models and Knowledge Graphs for Question Answering. *arXiv preprint arXiv:2104.06378v5*.